2020년 한양대학교

소프트웨어융합 종합학술대회

[분야: 인턴십/캡스톤]

제목: The Data Civilizer System

강은지(18학번), 석예림(18학번), 박서연(18학번)


2020. 12. 01



한양대학교 SW중심대학사업단

The Data Civilizer System





end-to-end 빅데이터 관리 시스템

Linkage Graph

데이터에 대한 링크 그래프 구축

Discovery

링크 그래프를 활용하여 사용자 작업에 관련한 데이터 식별



- 링크 그래프를 사용하여 join path 찾기
- 실제 query 실행에서 polystore DBMS사용
- 데이터 클리닝 작업을 query에 통합

Data preprocessing

- 결측치 제거

- Outlier 제거


- 날짜 데이터 유효성 검사



Data Profiling: pipeline →조


- pandas_profiling 라이브러리를 사용하여 profiling진행 및 메타 데이터 추출







- 칼럼 간 유사성 및 inclusion dependency 계산 구현



Data Update

- 데이터베이스 쿼리로그를 읽어와서 업데이트가 된 테이블에 대하여 프로파일링 재진행
- 기존 프로파일링과 비교하여 바뀐 사항 업데이트

DB의 query log

SELECT * FROM mysql.general_log ORDER BY event_time DESC LIMIT 5;

event_time	 user_host	thread_id	server_id	command_type	argument
2020-09-06 00:12:33.792293 2020-09-06 00:12:33.795262 2020-09-06 00:12:33.795886	root[root] @ localhost [::1] [root] @ localhost [::1] root[root] @ localhost [::1] root[root] @ localhost [::1] root[root] @ localhost [::1]	8 9 9 9 9 9 9 9 9 9 9 9 9 9 9 9 9 9 9 9	1		SELECT * from mysql.general_log root@localhost as anonymous on capstone SET AUTOCOMMIT = 0 SHOW TABLES DROP TABLE test1

저장되어 있는 마지막 쿼리문의 시간보다 최근의 쿼리문만 모두 불러오기


```
SELECT *
FROM mysql.general_log
WHERE event_time > '2020-09-06 00:14:55'
ORDER BY event_time DESC;

INSERT INTO test3 (Name, Classification, Type)
VALUES ('07WK3:D12900', '절토사면', '도로사면')

불러온 쿼리문에서 테이블명 추출
-> profile 진행
```




Data Civilizer System Structure






Data Civilizer 구현 결과

- ArangoDB에 테이블의 메타데이터 입력




- 칼럼간 유사성 및 inclusion dependency 데이터 입력






Data Civilizer 구현 결과

FOR x IN relation RETURN x





FOR x IN relation FILTER x.value > 0.3 RETURN x

